

Análisis estocástico de la evaluación de la contaminación por partículas finas PM2.5 en el Valle de Aburrá utilizando modelos de cadena de Markov

David Santiago Bautista Sierra^{1*},
Diego Alejandro Becerra Becerra^{1†},
Jorge Andres Sanchez Duarte^{1†},
Samuel Hernando Sanchez Gutierrez^{1†},
Viswanathan Arunachalam^{1†}

^{1*}Departamento de Estadística, Universidad Nacional de Colombia,
Bogotá , Colombia .

*Corresponding author(s). E-mail(s): dabautista@unal.edu.co;
Contributing authors: dibecerrab@unal.edu.co; josanchezdu@unal.edu.co
; josanchezdu@unal.edu.co ; varunachalam@unal.edu.co;
[†]Estos autores contribuyeron igualmente a este trabajo

Abstract

Este estudio se centra en la evaluación de la calidad del aire en el Valle de Aburrá, con un enfoque particular en la interacción espacial mediante el uso de un modelo espacial de cadena de Markov (SMC). Se examinan datos diarios de partículas finas PM2.5, recopilados desde abril de 2023 a marzo de 2024 con una frecuencia horaria en 16 estaciones de monitoreo de calidad del aire distribuidas en el Valle de Aburrá, Antioquia. Para el análisis de estos datos se emplea las clasificaciones del Índice de Calidad del Aire (ICA) como estados de una cadena de Markov y se establece la matriz de transición utilizando el método de estimación de máxima verosimilitud. Luego, se evalúa la proporción a largo plazo de cada estado y el tiempo medio de recurrencia con el objetivo de describir las características específicas de la calidad del aire en el contexto regional. Posteriormente, se procede a analizar la distribución de la concentración de PM2.5 mediante el modelo SMC (*Spatial Markov Chain*), donde se calcula la autocorrelación espacial con el fin de determinar si existe una dependencia espacial del PM2.5 en las

regiones. Este hallazgo sugiere que los niveles de contaminación del aire en una estación específica pueden estar correlacionados con los niveles de contaminación de estaciones vecinas. Los resultados de este estudio buscan comprender mejor la dinámica de la contaminación del aire en el Valle de Aburrá y evaluar su impacto en la salud pública y el medio ambiente.

Keywords: keyword1, Keyword2, Keyword3, Keyword4

1 Introducción

La inquietud respecto a la calidad del aire se ha convertido en un tema central en numerosas áreas geográficas, y el Valle de Aburrá no queda al margen de esta preocupación. En un contexto de crecimiento urbano y desarrollo industrial, la dinámica de contaminación atmosférica en esta región colombiana ha adquirido una importancia significativa, impulsando la necesidad de un análisis profundo.

Este proyecto investigativo se enfoca en comprender la evolución de la concentración de partículas finas PM_{2.5} en el Valle de Aburrá, utilizando un enfoque metodológico basado en un modelo de cadenas de Markov en tiempo discreto y un modelo de cadenas de Markov espacial. Esta elección metodológica no solo responde a la complejidad inherente de la contaminación del aire en la región, sino que también busca proporcionar un marco analítico riguroso para evaluar la efectividad de las medidas implementadas para abordar este desafío ambiental.

Las cadenas de Markov en tiempo discreto son una herramienta poderosa para modelar y analizar sistemas dinámicos, como la evolución de la contaminación atmosférica, en intervalos de tiempo definidos. Al incorporar la dimensión espacial con las cadenas de Markov espaciales, se puede capturar con precisión tanto las variaciones temporales como las espaciales en la concentración de contaminantes, lo que facilita una comprensión detallada de su evolución y de los posibles patrones de cambio a lo largo del tiempo y el espacio.

Además, las cadenas de Markov son especialmente útiles para modelar procesos estocásticos, es decir, aquellos en los que las transiciones entre estados futuros dependen únicamente del estado presente y no de la historia pasada del sistema. En el contexto de la contaminación atmosférica, donde múltiples factores influyen en la concentración de contaminantes y donde la interacción entre estos factores puede ser compleja, este enfoque simplificado pero robusto resulta invaluable para capturar la dinámica subyacente de manera efectiva.

A través del análisis de datos recopilados y la aplicación de modelos estadísticos avanzados, este estudio aspira a proporcionar información precisa y detallada sobre la evolución de la contaminación del aire en el Valle de Aburrá. Además, se pretende ofrecer recomendaciones concretas para mejorar la calidad del aire y proteger la salud de la población del Valle de Aburrá, así como para orientar futuras investigaciones y políticas ambientales.

En este estudio primero se emplea un modelo de cadena de Markov en tiempo discreto para la matriz global de todas las estaciones de monitoreo de calidad de aire

(ICA) para analizar su comportamiento en la concentración de PM2.5, un material particulado altamente peligroso que se origina en varias fuentes de combustión,. Utilizando las categorías del Índice de Calidad del Aire (ICA) en el valle de Aburrá como estados, se determinan las probabilidades de transición, los tiempos promedio de persistencia y retorno y las distribuciones estacionarias, también se emplea un modelo de cadena de Markov espacial (SMC) para analizar los datos de concentración de PM2.5 y representar la compleja dinámica espacio-temporal de la contaminación del aire en el Valle de Aburrá. Mediante el uso del método de máxima verosimilitud, se estima la matriz de probabilidad de transición que captura las interacciones dependientes espacialmente entre las estaciones de monitoreo de la calidad del aire. Este enfoque permite comprender cómo la contaminación del aire se propaga y se distribuye geográficamente en la región.

Estos análisis proporcionan información detallada sobre las características específicas de la contaminación del aire en diferentes áreas del Valle de Aburrá, lo que permite identificar patrones y tendencias significativas. También se lleva a cabo una investigación exhaustiva sobre la autocorrelación espacial en los datos de calidad del aire de todas las estaciones de monitoreo. Esto permite detectar posibles relaciones espaciales entre las concentraciones de PM2.5 en diferentes ubicaciones dentro del Valle de Aburrá, lo que ayuda a comprender mejor la propagación y distribución de la contaminación atmosférica en toda la región.

2 Metodología

2.1 Recolección de Datos

Se tomaron datos de calidad del aire referentes a la concentración de PM2.5 en Medellín y el Valle de Aburrá. Estos datos fueron proporcionados por el Sistema de Alerta Temprana de Medellín y el Valle de Aburrá - SIATA, un proyecto de Ciencia y Tecnología del Área Metropolitana del Valle de Aburrá y la Alcaldía de Medellín, que cuenta con el apoyo y los aportes de EPM e Isagen.

Los datos abarcaron un período comprendido entre el 1 de abril de 2023 y el 31 de marzo de 2024, permitiendo así un análisis significativo de la concentración de PM2.5 en Medellín y el Valle de Aburrá durante dicho lapso. Además, se tomaron 16 de las estaciones de monitoreo de la calidad del aire para llevar a cabo un análisis detallado, ya que muchas de las estaciones elegidas no poseían transiciones entre dos de las tres categorías estudiadas o inclusive solo una de ellas. El análisis abarca un período específico que permita un análisis significativo de la concentración de PM2.5 en el Valle de Aburrá. Se seleccionará un rango de fechas apropiado para capturar la variabilidad estacional y temporal de la contaminación del aire en la región.

2.2 Definición de Estados

Se utilizará el índice de calidad del aire (ICA) como base para definir los estados de la cadena de Markov. Se establecerán seis estados basados en la clasificación del ICA mostrados en la Tabla 1.

Table 1 Índice de calidad del aire (ICA) PM_{2,5} 24h (g/m³)

Estado	Descripción	PM _{2,5} 24h (g/m ³)
VERDE (Buena)	Ninguna.	0,0 – 15,4
AMARILLO (Moderada) $51 \leq \text{ICA} \leq 100$	Personas extremadamente sensibles con asma y adultos con enfermedad cardiovascular como hipertensión arterial, enfermedad isquémica del miocardio o pulmonar como asma, enfisema y bronquitis crónica deben reducir la actividad física fuerte o prolongada.	15,5 – 40,4
ANARANJADO (Dañina a la salud para grupos sensibles) $101 \leq \text{ICA} \leq 150$	Personas con enfermedades cardíacas o respiratorias, mayores de 60 años y niños deben evitar la actividad física fuerte o prolongada.	40,5 – 65,4
ROJO (Dañina a la salud) $151 \leq \text{ICA} \leq 200$	Personas con enfermedades cardiovascular o respiratorias, mayores de 60 años y niños deben evitar actividad física fuerte o prolongada.	65,5 – 150,4
MORADO (Muy dañina a la salud) $201 \leq \text{ICA} \leq 300$	Personas con enfermedades cardíacas o respiratorias, mayores de 60 años y niños deben evitar cualquier actividad física en exteriores. Las demás personas deben evitar la actividad fuerte o prolongada.	150,5 – 250,4
MARRÓN (Peligrosa) $301 \leq \text{ICA} \leq 500$	Todas las personas deben evitar el esfuerzo al aire libre.	250,5 – 500,4

2.3 Modelado con Cadena de Markov

Se aplicará un modelo de cadena de Markov para modelar la evolución temporal de la contaminación del aire en el Valle de Aburrá. Las transiciones entre estados se determinarán a partir de los datos recopilados y la clasificación del ICA.

2.4 Análisis de Datos

Se realizará un análisis detallado de los datos para identificar patrones, tendencias y áreas de especial atención en términos de contaminación atmosférica en el Valle de Aburrá. Esto permitirá comprender mejor la dinámica de la contaminación del aire y evaluar su impacto en la salud pública y el medio ambiente. El mapa de las estaciones de monitoreo son las siguientes:




Fig. 1 Mapa del Valle de Aburrá con las estaciones de monitoreo

2.5 Metodología de la cadena de Markov discreta para la construcción de la matriz de transición global

Las cadenas de Markov en tiempo discreto son una herramienta valiosa en el análisis de situaciones inciertas. Se utilizan para modelar la evolución de sistemas donde cada paso futuro depende únicamente del estado presente, sin verse afectado por lo que sucedió anteriormente. Esta propiedad, conocida como propiedad de Markov, simplifica la descripción de una secuencia de eventos, permitiendo analizar la transición entre estados con base únicamente en el estado actualm la formula es :

$$\begin{aligned}
 P(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) \\
 &= P(X_{n+1} = j \mid X_n = i) \\
 p_{ij} &= P(X_{n+1} = j \mid X_n = i)
 \end{aligned}$$

El valor p_{ij} es la probabilidad de transición de un paso y representa la probabilidad de pasar del estado i al estado j . La matriz de probabilidades de transición, P , para una cadena de Markov con S estados está compuesta por ss probabilidades de transición, p_{ij} , donde $0 \leq p_{ij} \leq 1$ y la suma de las probabilidades en cada fila es

igual a 1.

$$P = p_{ij} = \begin{bmatrix} p_{00} & p_{01} & \cdots & p_{0s} \\ p_{10} & p_{11} & \cdots & p_{1s} \\ \vdots & \vdots & \ddots & \vdots \\ p_{s0} & p_{s2} & \cdots & p_{s,s} \end{bmatrix}$$

Para obtener la matriz de probabilidad de transición de un estado a otro, se tiene:

$$\hat{p}_{ij} = \frac{n_{ij}}{\sum_{j=1}^m n_{ij}}$$

Distribución estacionaria

La distribución estacionaria de una cadena de Markov es la distribución de probabilidad que nos indica a largo plazo que un estado permanece sin cambios a medida que avanza el tiempo. Una cadena de Markov de estado finito que es ergódica tendrá cada fila de la distribución límite $\lim_{n \rightarrow \infty} P_n$ convergente a la distribución estacionaria. Sea π_j la proporción a largo plazo del tiempo pasado en un estado j . Si la cadena de Markov de estado finito es ergódica, es decir, aperiódica e irreducible, la distribución estacionaria es única y π_j se puede calcular por medio de:

$$\pi_j = \sum_{i=1}^s \pi_i p_{ij}$$

$$\sum_{j=1}^s \pi_i = 1$$

La distribución estacionaria muestra la proporción de tiempo a largo plazo que cada estación de monitoreo del aire pasa en una categoría de riesgo del IBOCA específica.

2.6 Aplicación del Modelo de Cadena de Markov Espacial: Autocorrelación ,Matriz de Transición y Dependencia Espacial

Autocorrelación espacial

La autocorrelación espacial se utiliza con el fin de investigar el análisis espacial de datos exploratorios, lo que permite detectar la dependencia espacial o la existencia de autocorrelación en los datos. Además, este método examina cuán similar es un punto de datos a otros puntos de datos a su alrededor, para comprender si los fenómenos observados están relacionados con el espacio (Rey et al., 2016; Kang y Rey, 2018). Las medidas más populares de autocorrelación espacial son la prueba de Moran's I, que es un indicador de autocorrelación espacial global, y la prueba Geary C, que es más sensible a la autocorrelación espacial local. Estas dos medidas se utilizan para probar cuán similar o diferente es un elemento a todos sus vecinos. El propósito de realizar la prueba de Moran's I es determinar si los datos del Índice de Calidad del Aire (API, por sus siglas en inglés) tienen un grado significativo de autocorrelación

espacial. Una estadística global de Moran's I que fue sugerida inicialmente por Moran (1948) se puede expresar como

$$I = \frac{N}{\sum_i \sum_j w_{ij}} \sum_i \sum_j w_{ij} \frac{(y_i - \bar{y})(y_j - \bar{y})}{h^2} / \frac{\sum_i \sum_j w_{ij}}{\sum_i (y_i - \bar{y})^2} = \frac{N}{S} \sum_i \sum_j w_{ij} z_i z_j / \sum_i z_i^2$$

(donde y_i y y_j son los valores del Índice de Calidad del Aire (API) para las regiones (estaciones) i y j , respectivamente, $\bar{y}$ es el promedio del API, N es el número total de unidades espaciales, y w_{ij} es el elemento de una matriz de pesos espaciales basada en la contigüidad de reina que describe la estructura espacial de las variables observadas entre las regiones disímiles, y S es el total de pesos espaciales. El puntaje Z para las estadísticas se puede expresar como)

$$ZI = \frac{I - E(I)}{\sqrt{V(I)}}$$

, donde

$$E(I) = -\frac{1}{N-1}$$

y

$$V(I) = E(I^2) - (E(I))^2$$

La idea principal de la estadística de Moran es evaluar si las dinámicas de transición enfrentadas por una región son afectadas por la condición de contaminación del aire de sus vecinos.

Una autocorrelación espacial positiva se indica por los valores de I que van de 0 a 1, mientras que una autocorrelación espacial negativa se indica por los valores de I que son mayores que 1.

Matriz de pesos espaciales

En este estudio, se utiliza un método novedoso para construir el contexto regional, o más formalmente, para proporcionar los pesos espaciales para 37 estaciones de monitoreo de aire. Primero, se construyen polígonos de Thiessen para las estaciones. Luego, se crean los pesos basados en la contigüidad de reina en función del polígono de Thiessen para puntos que representan las estaciones. Los procedimientos se completan convenientemente en solo un paso utilizando el software GeoDa (Anselin et al., 2006).

Formalmente, en la matriz de pesos espaciales W , cada elemento describe la interacción entre una entidad de región i y las entidades vecinas j , donde $j = 1, \dots, N$, si $i \neq j$, entonces $0 \leq w_{ij} \leq 1$ y si $i = j$, entonces $w_{ij} = 0$. Además, se cumple que $\sum_j w_{ij} = 1$ (Anselin et al., 2010; Rey et al., 2016).

Habiendo construido la matriz de pesos espaciales W , podemos calcular el retraso espacial para la región i en el tiempo t como

$$L_{i,t} = \sum_{j=1}^N w_{ij,t} d_{j,t}$$

(donde $w_{ij,t}$ representa los pesos que la región j contribuye al contexto local de la región i en el tiempo t y d_j es la observación. El contexto regional se ha formalizado considerando el rezago espacial de la región $L_{i,t}$, que refleja el promedio ponderado de los valores de las regiones vecinas. Más precisamente, si la región i está adyacente a

la región j , entonces $w_{ij} = 1$; de lo contrario, $w_{ij} = 0$, y $i, j = 1, 2, \dots, k$. Los rezagos espaciales para todas las regiones pueden escribirse como:)

$$L_t = W_t D_t$$

(formalizando las conexiones espaciales entre regiones de contaminación del aire en el tiempo t y D_t es el vector de contaminación del aire regional en el tiempo t (Rey et al., 2016; Kang y Rey, 2018). En este estudio, región se refiere a la estación.)

El modelo de cadena de Markov espacial

Los modelos de cadena de Markov espaciales (SMC), introducidos por primera vez por Rey (2001) como una extensión del modelo de cadena de Markov, permiten la influencia del contexto regional. El modelo SMC se presenta mediante la modificación de la matriz de probabilidad de transición, que condiciona las probabilidades de transición de una región en el estado inicial de contaminación del aire de su rezago espacial. Esta condición produce la matriz de probabilidad de transición espacial $\mathbf{P}_{k \times k \times k}$, que es una parte esencial del modelo SMC (Le Gallo 2004; Pu et al. 2005; Liu et al. 2016).


La matriz $\mathbf{P}_{k \times k \times k}$ es una matriz de probabilidad de transición tradicional de $k \times k$ expandida en k matrices condicionales de dimensión $k \times k$. Por lo tanto, esta matriz tiene en cuenta la dependencia espacial en forma de rezago espacial, es decir, condiciona la probabilidad de que una región específica se mueva hacia un estado, al estado en el que inicialmente se encontraban las regiones vecinas. Por ejemplo, si queremos identificar la influencia de las regiones vecinas con un estado grave de contaminación del aire en una región particular, podemos estimar la matriz condicional donde el rezago espacial (1) está en un estado muy insalubre o peligroso. La estimación de las matrices de probabilidad de transición condicionales del modelo de cadena de Markov espacial se lleva a cabo en función del método de máxima verosimilitud que se expresa como

$$\hat{p}(l)_{ij} = \frac{y(l)_{ij}}{y(l)_i}$$

donde y_{ij} es el número total de transiciones del estado de calidad del aire i en el tiempo t al estado j en el tiempo $t+1$ con el rezago espacial en estado l en t y $y(l)_i = \sum_{i=1}^N y_{ij}$ es el número total de transiciones que comienzan desde el estado de calidad del aire i . En general, $\hat{p}(l)_{ij}$ representa la probabilidad de transición de estado i a estado j dado que el rezago espacial está en el estado de contaminación del aire l (Rey et al. 2017).

3 Resultados y análisis

3.1 Matriz de transición global



La distribución estacionaria es:
[4.23641343e-01 5.35427130e-01 3.94087926e-02 1.37278654e-03
1.03807131e-04 4.61404421e-05]

Fig. 2 Matriz de transición Global y distribución estacionaria

Interpretación: Las probabilidades de transición globales entre los estados de contaminación del aire se estiman utilizando el método de máxima verosimilitud. Los valores en la diagonal de la matriz indican la probabilidad de permanecer en los respectivos estados de calidad del aire a lo largo del tiempo, mientras que los valores distintos de los de la diagonal muestran la probabilidad de transición entre diferentes estados de contaminación del aire durante todo el período de estudio. Otra característica importante del modelo de cadena de Markov global es la distribución de estado estacionario, también conocida como distribución límite, que describe la proporción a largo plazo de cada estado de contaminación del aire y que puede definirse como $\pi P = \pi$.

- **Buena (0):** La proporción a largo plazo es 42.36%. Esto significa que, a lo largo del tiempo, aproximadamente el 42.36% del tiempo, la calidad del aire será clasificada como “Buena”.
- **Moderada (1):** La proporción a largo plazo es 53.54%. Esto significa que, a lo largo del tiempo, aproximadamente el 53.54% del tiempo, la calidad del aire será clasificada como “Moderada”.
- **Dañina a la salud para grupos sensibles (2):** La proporción a largo plazo es 3.94%. Esto significa que, a lo largo del tiempo, aproximadamente el 3.94% del tiempo, la calidad del aire será clasificada como “Dañina a la salud para grupos sensibles”.
- **Dañina a la salud (3):** La proporción a largo plazo es 0.137%. Esto significa que, a lo largo del tiempo, aproximadamente el 0.137% del tiempo, la calidad del aire será clasificada como “Dañina a la salud”.
- **Muy dañina a la salud (4):** La proporción a largo plazo es 0.010%. Esto significa que, a lo largo del tiempo, aproximadamente el 0.010% del tiempo, la calidad del aire será clasificada como “Muy dañina a la salud”.
- **Peligrosa (5):** La proporción a largo plazo es 0.005%. Esto significa que, a lo largo del tiempo, aproximadamente el 0.005% del tiempo, la calidad del aire será clasificada como “Peligrosa”.

La mayoría del tiempo, la calidad del aire estará en un estado “Buena” o “Moderada”, con una proporción conjunta de aproximadamente 95.90%. Los estados de mayor riesgo como “Dañina a la salud”, “Muy dañina a la salud” y “Peligrosa” son extremadamente raros, con proporciones conjuntas muy bajas.

3.2 Índice de Moran

```

Índice de Moran: 0.3213314636551925
p-valor: 0.0043359552826834945
Valor esperado del índice de Moran: -0.06666666666666667
Varianza del índice de Moran: 0.01849990273887333
Error estándar normalizado: 0.13601434754787206

```

Fig. 3 Índice de Moran

El valor de $I=0.321$ positivo indica una autocorrelación espacial positiva. En otras palabras, las estaciones de monitoreo con niveles similares de contaminación del aire tienden a agruparse. Un valor de 0.321 sugiere una moderada autocorrelación espacial, lo que implica que los niveles de calidad del aire en las estaciones cercanas no son completamente independientes entre sí.

p-valor: 0.0043359552826834945

El p-valor es muy pequeño (mucho menor que 0.05), lo que indica que la autocorrelación espacial observada es estadísticamente significativa. Esto significa que

podemos rechazar la hipótesis nula de independencia espacial y concluir que hay una relación espacial significativa entre los niveles de calidad del aire de las estaciones.

3.3 Pasos para encontrar la matriz de transición espacial

se debe primero a construir el contexto regional, o más formalmente, para proporcionar los pesos espaciales para 16 estaciones de monitoreo de aire. Primero, se construyen polígonos de Thiessen para las estaciones. Luego, se crean los pesos basados en la contigüidad de reina en función del polígono de Thiessen para puntos que representan las estaciones. Los procedimientos se completan convenientemente en solo un paso utilizando phyton (Anselin et al., 2006).




Fig. 4 Polígonos de thiessen




Fig. 5 Matriz de pesos espaciales

3.4 Matriz de transición espacial y los las pruebas LR y chi-cuadrado

Se construye la matriz de transición global

se realiza con el método de máxima verosimilitud que se expresa como

$$\hat{p}(l)_{ij} = \frac{y(l)_{ij}}{y(l)_i}$$

donde y_{ij} es el número total de transiciones del estado de calidad del aire i en el tiempo t al estado j en el tiempo $t+1$ con el rezago espacial en estado l en t y $y(l)_i = \sum_{j=1}^N y_{ij}$ es el número total de transiciones que comienzan desde el estado de calidad del aire i . En general, $\hat{p}(l)_{ij}$ representa la probabilidad de transición de estado i a estado j dado que el rezago espacial está en el estado de contaminación del aire l (Rey et al. 2017).




Fig. 6 Matriz espacial

Spatial Markov Test		
Number of classes: 6		
Number of transitions: 86704		
Number of regimes: 5		
Regime names: LAG0, LAG1, LAG2, LAG3, LAG4, LAG5		
Test	LR	Chi-2
Stat.	8325.861	8424.810
DOF	82	82
p-value	0.000	0.000

Fig. 7 test espacial de markov

Tabla 2 Tabla

Test	LR	Chi-2
Stat.	8325.861	8424.810
DOF	82	82
p-valor	0.001	0.001

Análisis de Cadenas de Markov Espaciales de la Calidad del Aire

El análisis de cadenas de Markov espaciales se utiliza para entender cómo las transiciones de estados de calidad del aire (Buena, Moderada, Dañina a la salud para grupos sensibles, Dañina a la salud, Muy dañina a la salud y Peligrosa) dependen de los estados de calidad del aire de las regiones vecinas. Los resultados presentados indican que la calidad del aire en una región está influenciada significativamente por la calidad del aire en las regiones vecinas.

Las pruebas estadísticas utilizadas incluyen el estadístico de razón de verosimilitud (LR) y el estadístico de chi-cuadrado (Chi-2), ambos con grados de libertad (DOF) de 82.

- LR Stat.: 8325.861
- Chi-2 Stat.: 8424.810
- p-valor: 0.000

El p-valor de ambas pruebas es extremadamente bajo (0.000), lo que indica que las pruebas son significativas y podemos rechazar la hipótesis nula de independencia espacial condicional. Esto significa que hay una dependencia espacial significativa entre las regiones vecinas en términos de los estados de contaminación del aire.

Matriz de Probabilidad de Transición Espacial

Las matrices de probabilidad de transición espacial para diferentes rezagos espaciales (LAG0, LAG1, LAG2, LAG3, LAG4) muestran cómo las probabilidades de transición cambian en función de los estados de las regiones vecinas.

- **LAG0:**

- La probabilidad de que un estado bueno (C0) permanezca en buen estado es 0.844 cuando sus vecinos están en buen estado.
- La probabilidad de que un estado moderado (C1) permanezca en moderado es 0.495 cuando sus vecinos están en estado moderado.
- La probabilidad de que un estado dañino a la salud para grupos sensibles (C2) permanezca en el mismo estado es 0.045 cuando sus vecinos están en el mismo estado.

- **LAG1:**

- La probabilidad de que un estado bueno (C0) permanezca en buen estado es 0.741 cuando sus vecinos están en buen estado.
- La probabilidad de que un estado moderado (C1) permanezca en moderado es 0.615 cuando sus vecinos están en buen estado.
- La probabilidad de que un estado dañino a la salud (C3) permanezca en el mismo estado es 0.222 cuando sus vecinos están en buen estado.

- **LAG2:**

- La probabilidad de que un estado bueno (C0) permanezca en buen estado es 0.637 cuando sus vecinos están en estado moderado.
 - La probabilidad de que un estado moderado (C1) permanezca en moderado es 0.721 cuando sus vecinos están en estado moderado.
 - La probabilidad de que un estado dañino a la salud para grupos sensibles (C2) permanezca en el mismo estado es 0.217 cuando sus vecinos están en estado moderado.
- **LAG3:**
 - La probabilidad de que un estado bueno (C0) permanezca en buen estado es 0.541 cuando sus vecinos están en estado insalubre.
 - La probabilidad de que un estado moderado (C1) permanezca en moderado es 0.817 cuando sus vecinos están en estado insalubre.
 - La probabilidad de que un estado dañino a la salud para grupos sensibles (C2) permanezca en el mismo estado es 0.296 cuando sus vecinos están en estado insalubre.
- **LAG4:**
 - La probabilidad de que un estado bueno (C0) permanezca en buen estado es 0.503 cuando sus vecinos están en estado muy insalubre.
 - La probabilidad de que un estado moderado (C1) permanezca en moderado es 0.858 cuando sus vecinos están en estado muy insalubre.
 - La probabilidad de que un estado dañino a la salud para grupos sensibles (C2) permanezca en el mismo estado es 0.570 cuando sus vecinos están en estado muy insalubre.

Conclusiones Generales

- **Calidad del Aire Predominante:** La calidad del aire en Medellín y el Valle de Aburrá tiende a estar en los estados de “Buena” o “Moderada” la mayor parte del tiempo. Esto indica que, en general, las condiciones de aire son bastante buenas, aunque pueden fluctuar.
- **Raridad de Estados Críticos:** Los niveles de contaminación más graves (“Dañina a la salud”, “Muy dañina a la salud” y “Peligrosa”) son extremadamente raros. La presencia de estos estados críticos es infrecuente, sugiriendo que los episodios de alta contaminación son excepcionales.
- **Autocorrelación Espacial:** Existe una autocorrelación espacial significativa en los datos de calidad del aire, lo que indica que las estaciones cercanas muestran niveles similares de contaminación. Esto sugiere que las condiciones de calidad del aire en una región están influenciadas por las condiciones en áreas vecinas.
- **Dependencia Espacial:** La calidad del aire en una región no es independiente de la calidad del aire en regiones cercanas. Los resultados estadísticos muestran una dependencia espacial significativa, indicando que los niveles de contaminación en una área tienden a estar correlacionados con los niveles en áreas adyacentes.
- **Estabilidad de Estados:** La probabilidad de que un estado de calidad del aire se mantenga en el mismo estado es alta, especialmente para los estados de “Buena”

y “Moderada”. Esto sugiere una estabilidad en los niveles de contaminación, con pocas transiciones entre estados en la mayoría de los casos.

4 Bibliografía

- Alyousifi, Y., Ibrahim, K., Kang, W., Zin, W. Z. W. (2020). Modeling the spatio-temporal dynamics of air pollution index based on spatial Markov chain model. *Environmental monitoring and assessment*, 192, 1-24.